基于SCRIN改进网络社区发现算法识别基因本体的研究

李哲夫 清华大学生命科学学院（组长）（无其他小组成员）

摘要： 基因本体（Gene Ontology, GO）的系统化注释对于理解基因功能至关重要。本研究提出了一种基于改进网络社区发现算法的框架，旨在从基因互作网络中自动识别具有层次结构的基因功能模块，并与已知的GO注释进行比较验证。我们以经典的Louvain算法作为基线方法，并在此基础上进行了并行化改进以提升效率。同时，实现了谱聚类算法以应对复杂社区结构，并创新性地提出了多种针对生物网络“Hub”节点的边权调整与子图分割策略。通过GO富集分析的一致性评分和基因覆盖率评估，我们发现部分改进算法在社区功能一致性上显著优于基线方法。本研究为从复杂生物网络数据中推断基因功能层次结构提供了一种有效的无监督计算方法。

关键词： 基因本体；社区发现；Louvain算法；谱聚类；蛋白质相互作用网络；并行计算

1. 引言

理解基因及其产物在细胞中的功能是生命科学的核心问题之一。基因本体（GO）提供了一个结构化的、标准化的功能描述词汇表，但其构建与维护严重依赖人工审阅，成本高昂。与此同时，高通量技术产生了海量的生物分子互作数据（如蛋白质-蛋白质相互作用、基因共表达等），这些数据天然构成网络，其中功能相近的分子倾向于紧密连接。因此，**利用无监督的社区发现算法从这些网络中自动挖掘功能模块，并与GO进行比较验证**，成为一个极具潜力的研究方向。

本项目旨在开发并优化一系列网络社区发现算法，特别是能够揭示**层次化社区结构**的算法，以期恢复或补充GO所描述的功能层次体系。我们以SCRIN等项目提供的RNA共定位网络数据为起点，通过算法改进提升社区发现的准确性、效率及生物学可解释性。

基于空间转录组学方法SCRIN（https://github.com/xryanglab/SCRIN）产生的新的互作类型，我们可以检测mRNA共定位信息所表征的基因社区。

2. 项目框架与方法

本项目的整体框架如github所示（https://github.com/zf-li23/Gene_Ontology），核心流程包括数据输入、社区发现算法执行、结果优化与验证。

输入数据： 主要来源于SCRIN等工具处理的RNA分子共定位数据，该数据暗示了分子间潜在的共迁移、相分离或功能协作关系，可构建无权或有权的分子互作网络。

核心算法： 我们实现并比较了多种算法，以经典Louvain算法作为性能评估的基线：

1. **基线算法：** 经典的Louvain算法。
2. **改进算法：**
    - 层次化递归Louvain算法。
    - 谱聚类算法。
    - 针对Hub节点的边权调整算法（`div`系列）。
    - 针对Hub节点的子图分割手术算法（`algorithm2`和`algorithm3`）。

输出与验证： 算法输出不同层次的社区划分，随后通过GO富集分析计算每个社区的**功能一致性评分**与**基因覆盖率**，从而定量评估算法的有效性。

3. 算法原理与优化

3.1 基线算法：经典Louvain算法

Louvain算法是一种基于贪心优化思想的高效社区发现算法，以最大化网络**模块度**为目标。模块度是衡量社区划分质量的一个指标，其值越高表明社区内部连接越紧密，社区之间连接越稀疏。算法分为两个阶段迭代进行：

1. **局部优化：** 遍历每个节点，计算将其移动到邻居节点所在社区带来的模块度增益，并执行增益最大的移动。
2. **网络凝聚：** 将第一阶段归入同一社区的所有节点聚合为一个新的超节点，构建出一个压缩后的新网络。
   算法在上述两个阶段间迭代，直至模块度不再增长，从而自然产生一个社区层次结构。由于其高效性和良好的效果，Louvain算法成为网络社区发现领域的经典基线方法。

3.2 并行化Louvain算法

为处理更大规模的网络，我们在经典Louvain算法的基础上引入了并行化策略。核心思想是构造多个彼此间**闭邻域不重叠**的顶点集合（称为`isolate_sets`）。在每个迭代周期内，算法可以安全地在不同线程上并行处理这些集合内部的顶点移动，因为集合间的顶点移动互不影响，从而避免了数据竞争，无需加锁。算法流程如算法1伪代码所示。

```
算法1：ParallelLouvain(G, isolate_sets, T)
输入：图 G, isolate_sets, 线程数 T
输出：顶点到社区映射 C: V → ℤ
    C ← {v → v_id}  # 初始化为单例社区
    ΔQ ← ∞
    while ΔQ > threshold do
        # 在 isolate_sets 上并行循环
        for S_i in isolate_sets (parallel for T threads) do
            for v in S_i do
                best_comm ← argmax_{c∈N(v)} ΔQ(v→c) # 寻找最佳模块度增益社区
                if ΔQ(v→best_comm) > 0 then
                    C[v] ← best_comm  # 无锁更新社区标签
                end
            end
        end
        # 同步阶段：聚合社区，构建新图，计算模块度变化
        G' ← aggregate_communities(G, C)
        ΔQ ← compute_modularity(G') - compute_modularity(G)
    end
    return C
```

3.3 谱聚类算法

谱聚类能够识别形状复杂的社区，其核心是将网络节点映射到拉普拉斯矩阵特征向量构成的空间中进行聚类。

数学原理与步骤：

1. 给定图 $G = (V, E)$ 及目标社区数 k，构建邻接矩阵 A 和度矩阵 D。
2. 计算归一化拉普拉斯矩阵 $L = I - D^{-1/2}AD^{-1/2}$。
3. 计算 L 的前 k 个最小特征值对应的特征向量 $u_1, \ldots, u_k$。
4. 形成特征矩阵 $U = [u_1, u_2, \ldots, u_k] \in \mathbb{R}^{|V| \times k}$。
5. 将 U 的每一行 y_i 视为节点在 $\mathbb{R}^k$ 空间的新坐标。

6. 使用K-means算法对点集 $\{y_i\}$ 聚类成 k 类。
7. 将聚类标签映射回原网络节点，得到社区划分。

3.4 针对“Hub”节点的改进策略

真实生物网络常呈现无标度特性，存在大量连接数极高的“Hub”节点（如a）

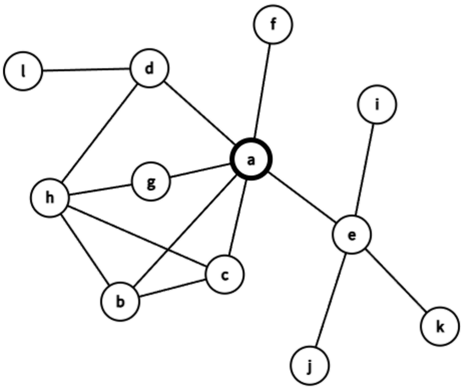

这会影响社区发现的质量。我们提出三类改进策略：

算法1：基于度的边权调整
为削弱Hub节点对社区结构的过度影响，我们尝试对其连边权重进行标准化：

- `div1`：边权除以源节点的度。

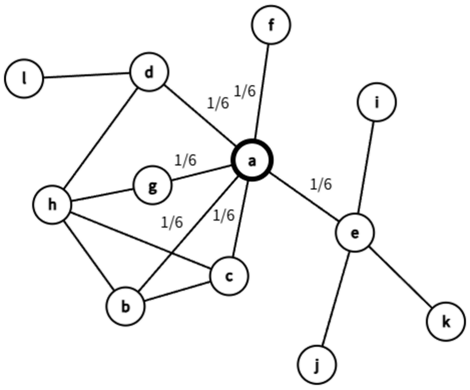

- `div2`：边权除以源节点的度的平方。

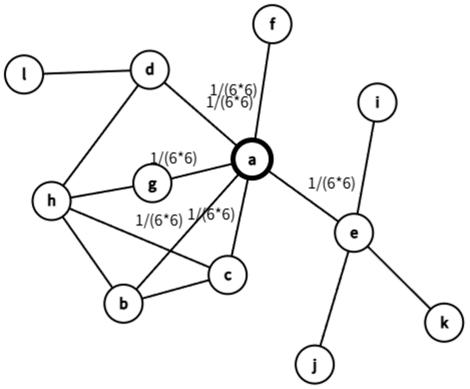

- `div0.5`: 边权除以源节点的度的平方根。

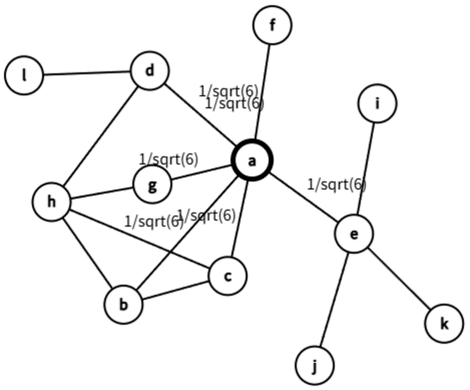

- `div avg`: 边权除以该边两端节点度乘积的平方根。

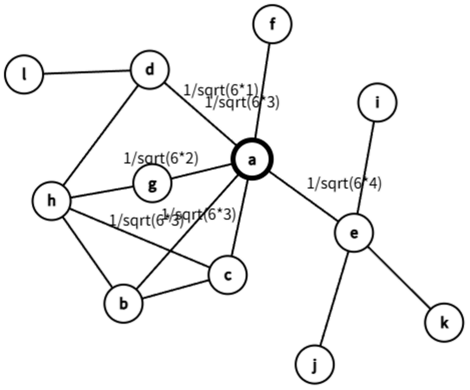

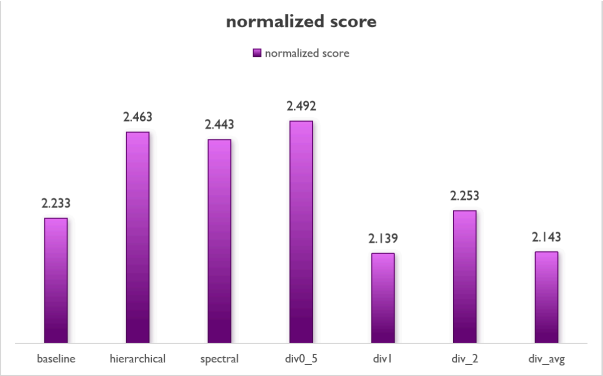

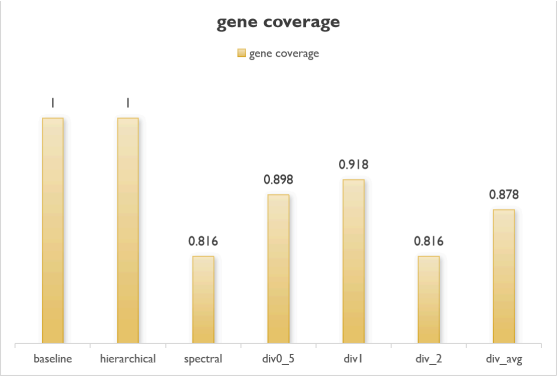

算法2/3：基于“类团”识别的子图手术

Hub节点通常连接多个功能模块。我们提出识别其邻域中的密集子结构（“类团”或“最大类团”），并将Hub节点复制为多个“虚拟节点”，每个虚拟节点分别连接到一个“类团”中的节点。这相当于对Hub节点进行“手术”，将其功能解耦到不同的潜在社区中。

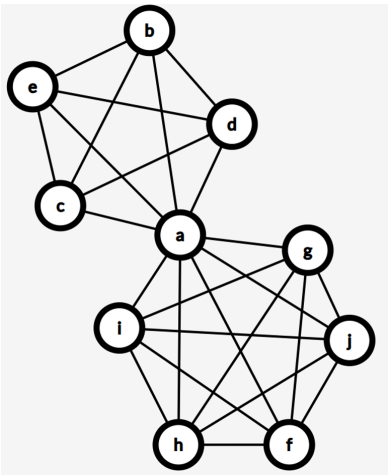

算法2允许类团重叠：

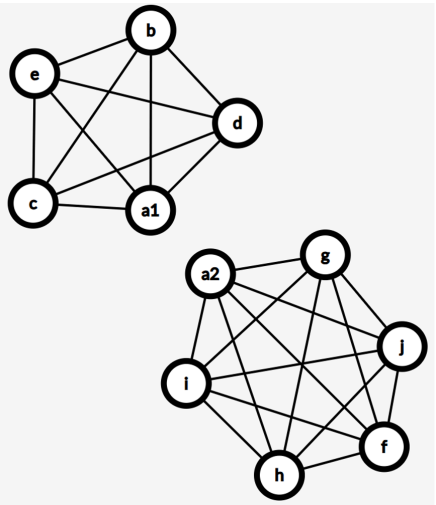

算法3寻找不重叠的最大类团进行更精确的手术：

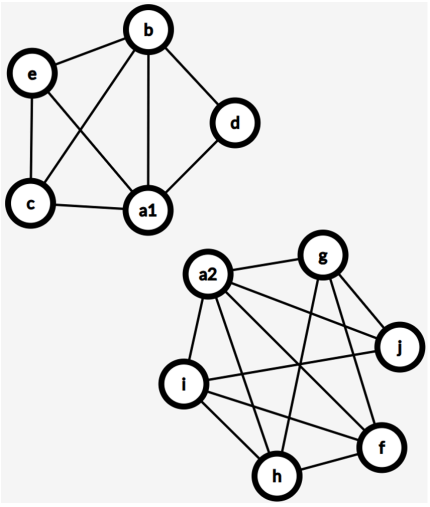

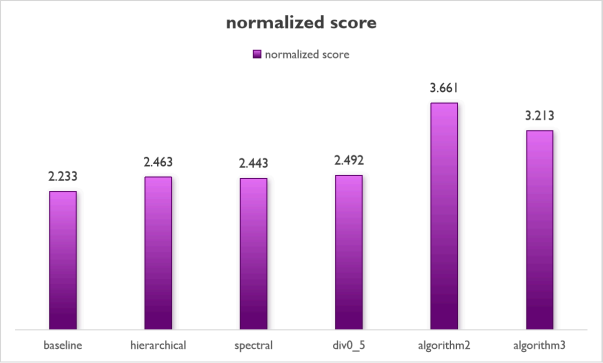

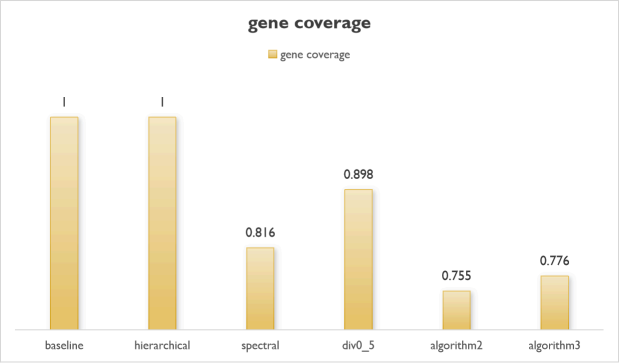

4. 实验结果与分析

我们使用基准数据测试了所有算法的性能，并通过GO富集分析计算了每个算法输出社区的**功能一致性归一化评分**（评分越高，表明社区内基因的功能越一致）和**基因覆盖率**（被划分到社区中的基因占网络总基因的比例）。定量评估结果如表1所示。另外，可以自动生成所有算法的评分报告，使用方法在github仓库中README说明文档中。

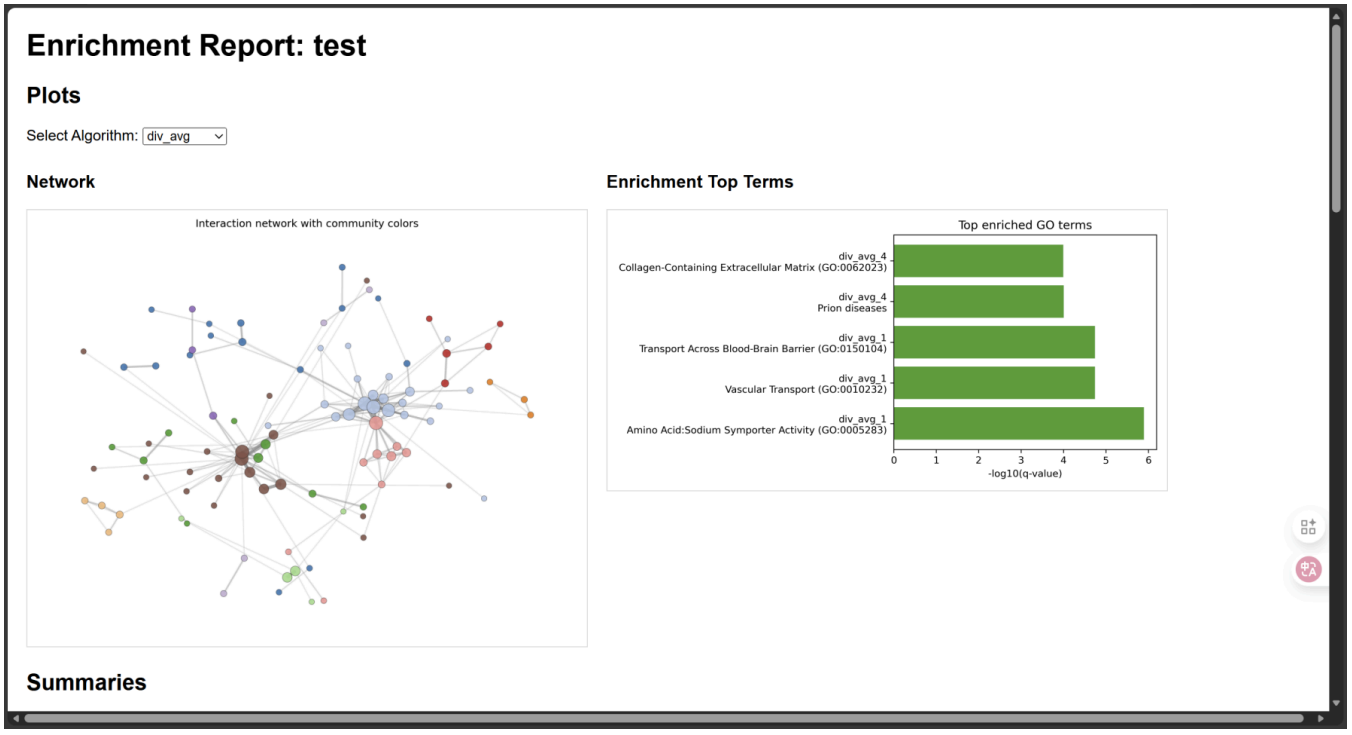

表1：不同社区发现算法性能评估结果

算法名称	社区数量	功能一致性评分	基因覆盖率	主要特点
baseline (Louvain)	17	2.233	1.000	经典算法，覆盖率最高，作为比较基线。
hierarchical (层次化Louvain)	24	**2.463**	1.000	发现更多细分社区，功能一致性显著提升。
spectral (谱聚类)	9	2.443	0.816	基于图谱划分，一致性较高，但覆盖率下降。
div_0_5	9	**2.492**	0.898	边权除以度的平方根，在一致性上表现最佳。
div_1	12	2.139	0.918	边权除以度，性能与基线相近或略低。
div_2	12	2.253	0.816	边权除以度的平方，惩罚最强，一致性有所回升。
div_avg	11	2.143	0.878	基于两端节点度的均衡调整，效果不突出。
algorithm2	3	**3.661**	0.755	Hub手术算法2，**一致性评分最高**，但社区数量锐减，覆盖率降低。
algorithm3	3	**3.213**	0.776	Hub手术算法3，一致性同样很高，与算法2形成对比。

结果分析：

1. **层次化Louvain**在保持100%基因覆盖率的同时，获得了比基线Louvain更高的功能一致性评分，说明其发现的更细粒度的社区具有更强的功能内聚性。
2. 谱聚类算法（`spectral`）展现出不俗的一致性（2.443），验证了其在复杂结构网络上的有效性。
3. 边权调整策略中，`div_0_5` 取得了该系列最好的效果（2.492），表明对Hub节点连边进行适度削弱（开根号）最能提升社区功能一致性。
4. 最为显著的是，两种Hub手术算法（`algorithm2` 和 `algorithm3`）获得了**远超其他算法的一致性评分（>3.0）**。这表明将Hub节点解耦到不同功能模块的策略，能极大提升所识别社区的功能纯度。然而，这种策略的代价是社区数量大幅减少，且基因覆盖率降至75%-78%，暗示其可能过滤掉了大量信号或适用于特定的网络结构。

baseline：较为规整的聚类

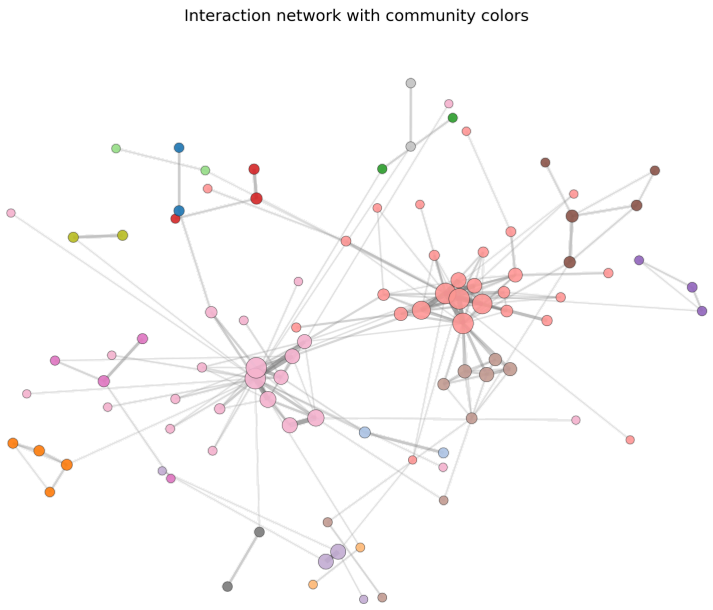

hierarchical：虽然从可视化的角度，看起来聚类效果下降，但评分提高，说明其聚类结果可能更具生物学意义。

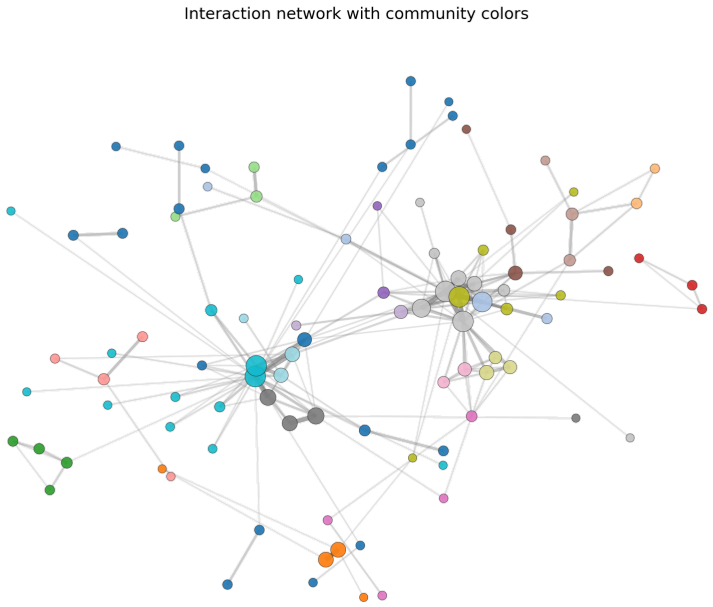

spectral：谱聚类算法较为传统，结果规整。

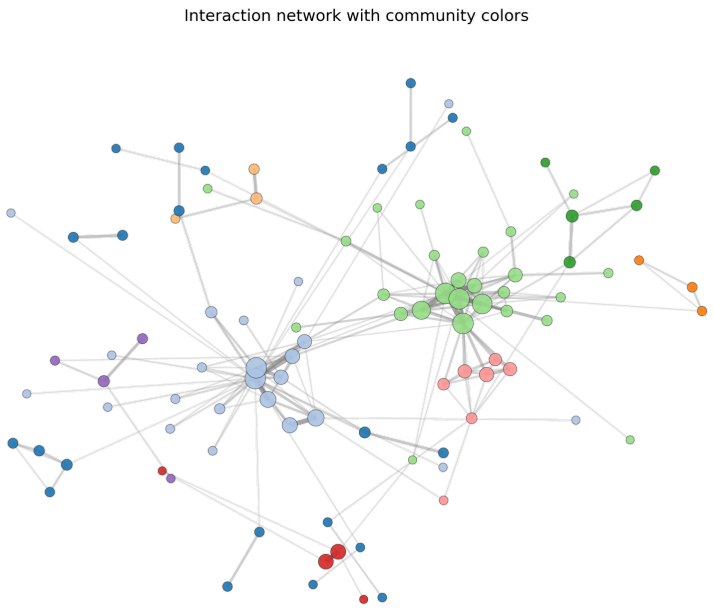

div：以效果最好的div_0.5为例，聚类效果与基准相近

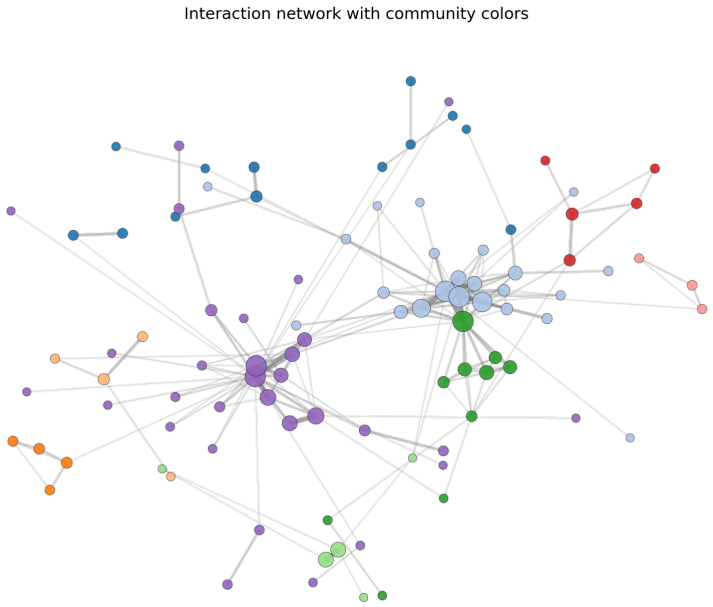

algorithm2：完成的聚类较少，这也是评分较高的因素之一。

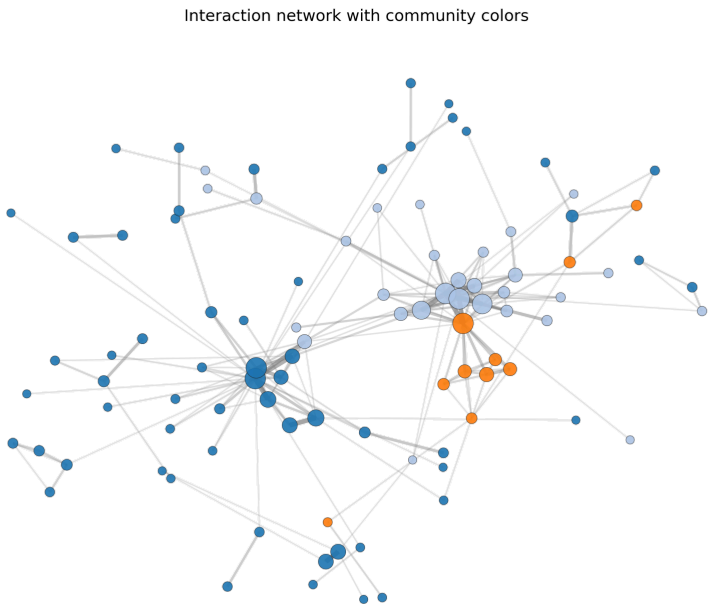

algorithm3：与algorithm2相似。

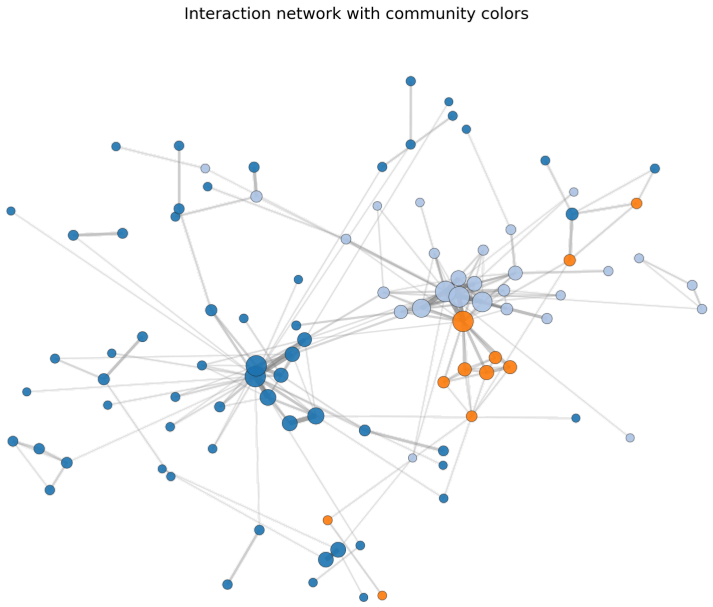

5. 讨论与未来展望

实验结果表明，通过算法改进，尤其是针对生物网络特性的改进（如处理Hub节点），可以有效提升社区发现结果在功能层面的可解释性。然而，**功能一致性的提升与基因覆盖率之间存在着权衡关系。**未来的工作将集中于：

1. **数据对接与扩展：** 将已验证的算法应用于更权威、规模更大的蛋白质-蛋白质相互作用网络（如STRING数据库），检验其普适性。
2. **算法优化与平衡：** 深入研究Hub手术算法，探索如何在保持高功能一致性的前提下，提升其社区发现的数量和基因覆盖率。例如，设定更精细的“类团”检测阈值。
3. **系统评估与验证：** 引入更多的评估指标（如模块度、轮廓系数等），并结合KEGG通路等其他知识库进行交叉验证，建立更全面的算法评价体系。
4. **工具化与应用：** 将稳定高效的算法（如并行Louvain、`div_0.5`及改进后的Hub手术算法）封装成易用的软件

工具，服务于功能基因组学等领域的研究。

参考文献

Ravasz, E., Somera, A. L., Mongru, D. A., Oltvai, Z. N., & Barabási, A.-L. (2002). Hierarchical organization of modularity in metabolic networks. *Science*, 297(5586), 1551–1555. https://doi.org/10.1126/science.1073374

Hallinan, J. (2004). Gene duplication and hierarchical modularity in intracellular interaction networks. *BioSystems*, 74(1–3), 51–62. https://doi.org/10.1016/j.biosystems.2004.02.004

Wang, J., Li, M., Deng, Y., & Pan, Y. (2010). Recent advances in clustering methods for protein interaction networks. *BMC Genomics*, 11(Suppl 3), S10. https://doi.org/10.1186/1471-2164-11-S3-S10

Yang, Z., Perotti, J. I., & Tessone, C. J. (2017). Hierarchical benchmark graphs for testing community detection algorithms. *Physical Review E*, 96(5), 052311. https://doi.org/10.1103/PhysRevE.96.052311

Qie, H., Li, S., Dou, Y., Xu, J., Xiong, Y., & Gao, Z. (2022). Isolate sets partition benefits community detection of parallel Louvain method. *Scientific Reports*, 12(1), 8248. https://doi.org/10.1038/s41598-022-11987-y

Ge, B.-K., Hu, G.-M., Chen, R., & Chen, C.-M. (2022). MSClustering: A Cytoscape tool for multi-level clustering of biological networks. *International Journal of Molecular Sciences*, 23(22), 14240. https://doi.org/10.3390/ijms232214240

Wang, Y., Chen, Q., Yang, L., Yang, S., He, K., & Xie, X. (2021). Overlapping structures detection in protein-protein interaction networks using community detection algorithm based on neighbor clustering coefficient. *Frontiers in Genetics*, 12, 689515. https://doi.org/10.3389/fgene.2021.689515

Subelj, L., & Bajec, M. (2011). Unfolding communities in large complex networks: Combining defensive and offensive label propagation for core extraction. *Physical Review E*, 83(3), 036103. https://doi.org/10.1103/PhysRevE.83.036103